

Plan de manejo y documentación de datos

Proyecto: Impacto de los servicios prehospitalarios en la mortalidad y letalidad en accidentes de tránsito en Chile

Departamento de Salud Pública · Gabriel Matías Mansilla Lucero · 2025

1. Fuentes de datos

La fuente principal es la **base de datos de siniestros de tránsito a nivel de persona (2014–2024)** registrada por Carabineros de Chile y procesada por la Comisión Nacional de Seguridad de Tránsito (CONASET), archivo *Personas 2014-2024.xlsx*. Hasta 2018 los fallecidos se contabilizan hasta 24 horas después del siniestro y desde 2019 hasta 48 horas, lo que debe considerarse en la comparación entre años. Como fuentes secundarias de enlace se contempla información operativa del sistema prehospitalario (SAMU) —tiempos de respuesta, tipo de unidad y atención en terreno— y capas de geocodificación comunal/regional para el análisis territorial.

2. Unidad de análisis

La unidad de análisis es **la persona involucrada en un siniestro de tránsito** (conductor, pasajero, peatón, ciclista o motociclista). Cada registro corresponde a una persona, vinculada a su siniestro mediante un identificador de evento, lo que permite análisis tanto a nivel individual como agregado por comuna y región.

3. Almacenamiento y respaldo

Los datos crudos se almacenan en una carpeta local `data/` que **no se versiona** en el repositorio público. Se aplica la regla de respaldo **3-2-1**: tres copias, en dos medios distintos, con al menos una copia fuera de sitio (nube institucional cifrada). Se conserva una copia inalterable de los datos originales (solo lectura) y todo procesamiento se realiza sobre copias de trabajo. Los respaldos se verifican periódicamente y se documenta su ubicación en el plan interno del proyecto.

4. Confidencialidad y acceso

La base contiene información sensible de personas lesionadas y fallecidas, por lo que su tratamiento se rige por la Ley N.º 19.628 sobre protección de la vida privada y los principios de minimización y finalidad. Antes del análisis se **anonimiza** el conjunto: se elimina o reemplaza cualquier identificador directo por un código (*id_persona*), y se evalúan cuasi-identificadores territoriales/temporales para prevenir la reidentificación. El acceso a los datos individuales se restringe al equipo autorizado; el repositorio público difunde únicamente documentación, código y resultados agregados que no permitan identificar personas.

5. Documentación de las bases de datos

Cada base se documenta mediante un **diccionario de datos** (`docs/diccionario_datos.xlsx`) que describe, para cada variable, su nombre, descripción, tipo, unidad o categorías y codificación de valores permitidos, además de la fuente y el rol en el análisis. Toda transformación (recodificación, creación de variables derivadas, enlaces entre fuentes) queda registrada en los scripts de la carpeta `code/`, de modo que la base analítica sea trazable desde los datos crudos.

6. Nomenclatura de archivos y control de versiones

Los nombres de archivo usan minúsculas, sin espacios ni tildes, con guion bajo como separador y prefijos numéricos para indicar orden de ejecución. El control de versiones se realiza con **Git/GitHub**, con mensajes de commit descriptivos; los datos individuales quedan excluidos mediante `.gitignore`. Ejemplos de convención:

Elemento	Convención / ejemplo
Scripts	<code>NN_verbo_objeto.R</code> — p. ej. <code>01_preparacion_datos.R</code>
Salidas	<code>tipo_descripcion_vN.ext</code> — p. ej. <code>tabla_mortalidad_region_v2.csv</code>
Fechas	Formato ISO 8601: <code>AAAA-MM-DD</code>
Versiones	Etiquetas Git (<code>v1.0</code>) para hitos; el historial reemplaza los sufijos <code>'_final_final'</code>

7. Calidad de los datos

Se aplican controles sistemáticos: verificación de rangos y dominios (p. ej. edad 0–120, año dentro de 2014–2024, códigos regionales válidos), detección de duplicados y de valores fuera de categoría, tratamiento explícito y documentado de datos faltantes, y validación de los enlaces entre la base de personas y los registros prehospitales. Estas comprobaciones se implementan como aserciones dentro de los scripts, de modo que la preparación falle de forma visible si un supuesto no se cumple.

8. Reproducibilidad

El proyecto se organiza en un repositorio con estructura estándar (README, docs/, code/, outputs/, manuscripts/) y flujo de trabajo numerado desde los datos crudos hasta los resultados. Se emplean rutas relativas, semillas aleatorias fijas y registro del entorno computacional (versión de R/Python y de los paquetes, mediante `renv` o `requirements.txt`). El código y la documentación se publican con licencia abierta (MIT para código, CC BY 4.0 para documentación), de manera que un tercero pueda reproducir el análisis si dispone de acceso autorizado a los datos.